흡연 여부 데이터 분석을 통한 건강 인사이트 도출

Chill_Stack
박진영
설윤재
정은혜
진태준(조장)

목차

01 프로젝트 개요
02 분석 목표
03 데이터구조 및 탐색
04 데이터 시각화
05 단변량 & 이변량 분석
06 상관 관계 시각화
07 분석 결과
08 결론 및 인사이트

프로젝트 개요

- 흡연 여부는 건강에 큰 영향을 주지만 직접 조사에는 한계가 있음
- 객관적인 건강검진 데이터를 활용해 흡연 여부에 따른 건강 지표 차이를 분석

분석 목표

- 흡연 여부에 따른 신체 지표의 통계적 유의성 검증
- 연령대별 흡연 영향력의 차이 규명
- 구강 건강(충치) 및 대사 지표와 흡연의 연관성 파악
- 시각화를 통한 데이터 인사이트 도출
- 추후 흡연 여부 예측 모델 개발을 위한 기초 분석 기반 마련

데이터 구조

문자형 (Object)		ID
정수형 (Int)		나이, 키(cm), 몸무게(kg), 충치, 콜레스테롤, 고밀도지단백, 저밀도지단백, 요단백, label
실수형 (Float)		BMI, 시력, 공복 혈당, 혈압, 중성 지방, 혈청 크레아티닌, 헤모글로빈, 간 효소율
숫자형	연속형	키(cm), 몸무게(kg), BMI, 시력, 공복 혈당, 혈압, 중성 지방, 혈청 크레아티닌, 간 효소율, 헤모글로빈
	이산형	나이, 콜레스테롤, 고밀도지단백, 저밀도지단백
범주형	명목형	ID, 충치, label(흡연여부)
	순서형	요 단백

데이터 탐색

1. 필요한 라이브러리 설치

```
# 필요한 라이브러리들 불러오기

# 나눔폰트 설치 (Linux 명령어)
# !sudo apt-get install -y fonts-nanum
# !sudo fc-cache -fv
# !rm ~/.cache/matplotlib -rf

print("폰트 설치가 완료되었습니다. 반드시 '런타임 > 세션 다시 시작'을 누르고 아래 코드를 실행하세요!")

# 데이터 분석 및 처리용 라이브러리
import pandas as pd
import numpy as np

# 시각화 라이브러리
import matplotlib.pyplot as plt
import seaborn as sns

# 한글 폰트 설정 (그래프에서 한글 깨짐 방지)
plt.rc('font', family='NanumBarunGothic')
plt.rcParams['axes.unicode_minus'] = False # 마이너스 기호 깨짐

print("라이브러리 로딩 완료!")
```

```
폰트 설치가 완료되었습니다. 반드시 '런타임 > 세션 다시 시작'을 누르고 아래 코드를 실행하세요!
라이브러리 로딩 완료!
```

데이터 탐색

2. 데이터 프레임 구조 확인

```
# 아래에 실습코드를 작성하고 결과를 확인합니다.
health_data = pd.read_csv("smoking_health_data.csv")
```

```
# 아래에 실습코드를 작성하고 결과를 확인합니다.
health_data.shape
```

```
(7000, 18)
```

```
# 아래에 실습코드를 작성하고 결과를 확인합니다.
health_data.describe().round(2)

# 시력, 공복혈당, 혈압, 중성지방 컬럼에 결측치가 있음을 조기 확인
```

	나이	키(cm)	몸무게 (kg)	BMI	시력	충치	공복 혈당	혈압	중성 지방	혈청 크레아티닌	콜레스테롤	고밀도지단백	저밀도지단백	헤모글로빈	요 단백	간 효소율	label
count	7000.00	7000.00	7000.00	7000.00	6860.00	7000.00	6860.00	6860.00	6860.00	7000.00	7000.00	7000.00	7000.00	7000.00	7000.00	7000.00	7000.00
mean	43.97	164.78	65.93	24.14	1.01	0.23	99.31	45.56	127.03	0.88	197.28	57.36	115.35	14.63	1.08	1.14	0.37
std	12.06	9.17	12.98	3.50	0.43	0.42	21.19	8.83	73.22	0.24	36.31	14.51	41.79	1.54	0.39	0.43	0.48
min	20.00	135.00	30.00	14.27	0.10	0.00	57.00	14.00	21.00	0.10	86.00	18.00	1.00	4.90	1.00	0.14	0.00
25%	35.00	160.00	55.00	21.60	0.80	0.00	89.00	40.00	74.00	0.80	173.00	47.00	92.00	13.60	1.00	0.84	0.00
50%	40.00	165.00	65.00	23.88	1.00	0.00	96.00	45.00	107.00	0.90	195.00	55.00	113.00	14.80	1.00	1.10	0.00
75%	50.00	170.00	75.00	26.12	1.20	0.00	104.00	50.00	161.00	1.00	219.00	66.00	136.00	15.70	1.00	1.38	1.00
max	85.00	190.00	130.00	42.45	9.90	1.00	386.00	91.00	399.00	10.00	395.00	157.00	1340.00	20.90	5.00	5.67	1.00

충치	공복 혈당	혈압
7000.00	6860.00	6860.00

describe() 통해 빠르게 구조 파악 가능 -> 일부 컬럼에 결측치 사전 파악 가능

데이터 탐색

3. 결측치 확인 및 처리

```
# 원본 백업
health_data_filled = health_data.copy()
```

```
# label 컬럼 변경 -> 가독성 위해 흡연 여부로 변경
health_data_filled.rename(columns={'label': '흡연여부'}, inplace=True)
```

```
# 혈압 결측치 -> 중앙값으로 대체
bp_median = health_data_filled['혈압'].median()
health_data_filled['혈압'] = health_data_filled['혈압'].fillna(bp_median)
```

```
# 시력 결측치 -> 최빈값으로 대체
sight_mode = health_data_filled['시력'].mode()[0] # 최빈값 중 첫번째 최빈값
health_data_filled['시력'] = health_data_filled['시력'].fillna(sight_mode)
print("")
```

데이터 탐색

3. 결측치 확인 및 처리

```
# 나이대별 중성지방 -> 각 그룹 평균값으로 대체
health_data_filled['중성 지방'] = health_data_filled.groupby('age_group')['중성 지방'].transform(lambda x:
health_data_filled.groupby('age_group')['중성 지방']

# 공복 혈당 -> 평균값으로 대체
fasting_glucose_mean = health_data_filled['공복 혈당'].mean()
health_data_filled['공복 혈당'] = health_data_filled['공복 혈당'].fillna(fasting_glucose_mean)
print("")
```

데이터 탐색

3. 결측치 확인 및 처리

```
컬럼별 결측치 개수:
ID                    0
나이                   0
키(cm)                 0
몸무게(kg)              0
BMI                   0
시력                  140
충치                    0
공복 혈당               140
혈압                  140
중성 지방               140
혈청 크레아티닌              0
콜레스테롤                 0
고밀도지단백                 0
저밀도지단백                 0
헤모글로빈                 0
요 단백                  0
간 효소율                  0
label                 0
BMI_Category          0
age_group             0
dtype: int64
```

```
결측치 처리 후:
ID                    0
나이                   0
키(cm)                 0
몸무게(kg)              0
BMI                   0
시력                    0
충치                    0
공복 혈당                 0
혈압                    0
중성 지방                 0
혈청 크레아티닌              0
콜레스테롤                 0
고밀도지단백                 0
저밀도지단백                 0
헤모글로빈                 0
요 단백                  0
간 효소율                  0
흡연여부                   0
BMI_Category          0
age_group             0
dtype: int64
```

파생 변수 생성

파생 변수명	생성 기준	분류 값	생성 목적
BMI_Category	BMI 기준 구간화	저체중 / 정상 / 과체중 / 비만	체중 상태에 따른 건강 영향 분석
age_group	나이 구간화	30대 이하 / 30~50대 / 50~70대 / 70대 이상	연령대별 건강 지표 비교
흡연여부	label 값 변환	비흡연 / 흡연	시각화 및 해석 가독성 향상
충치여부	충치(0/1) 변환	없음 / 있음	범주형 분석 명확화

가설

가설 1

H_0 (귀무가설): **헤모글로빈** - 흡연자와 비흡연자의 평균 헤모글로빈 농도 차이가 없다.
H_1 (대립가설): **헤모글로빈** - 흡연자와 비흡연자의 평균 헤모글로빈 농도가 차이가 있다.

가설 2

H_0 (귀무가설): **요단백** - 흡연자와 비흡연자의 요단백 수치차이가 없다.
H_1 (대립가설): **요단백** - 흡연자와 비흡연자의 요단백 수치차이가 있다.

가설 3

H_0 (귀무가설): **충치** - 흡연자와 비흡연자의 충치 유무 비율차이가 없다.
H_1 (대립가설): **충치** - 흡연자와 비흡연자의 충치 유무 비율차이가 있다.

가설 4

H_0 (귀무가설): **공복 혈당** - 흡연 여부에 따른 공복 혈당 차이가 없다.
H_1 (대립가설): **공복 혈당** - 흡연 여부에 따른 공복 혈당 차이가 있다.

가설 5

H_0 (귀무가설): **BMI** - 흡연 여부에 따른 비만 비율 차이가 없다.
H_1 (대립가설): **BMI** - 흡연 여부에 따른 비만 비율 차이가 있다.

단변량 분석

1. 흡연 여부에 따른 BMI 기본 통계 정보

```
# 연령별 나누기
age_order = ["30대 이하", "30~50대", "50~70대", "70대 이상"]
health_data_filled["age_group"] = pd.Categorical(health_data_filled["age_group"], categories=age_order, ordered=True)

# 범례 변경
health_data_filled['흡연여부'] = health_data_filled['흡연여부'].replace({0.0: '비흡연', 1.0: '흡연'})
```

```
# 흡연 여부에 따른 BMI 기본 정보
bp_by_smoking = round(health_data_filled.groupby("흡연여부")["BMI"].describe(),2)

print(bp_by_smoking)
print()
```

	count	mean	std	min	25%	50%	75%	max
흡연여부								
비흡연	4429.0	23.81	3.44	14.27	21.48	23.44	25.71	42.45
흡연	2571.0	24.73	3.53	15.57	22.49	24.22	27.06	40.82

단변량 분석

1. BMI box_plot

```python
#박스 플롯
bmi_mean_age_label = round(health_data_filled.groupby(["age_group", "흡연여부"],observed=False)["BMI"].mean().unstack(),2)
print("나이 그룹 + 흡연 여부별 평균 BMI")
print(bmi_mean_age_label)
print()

plt.figure(figsize=(8,5))
sns.boxplot(data=health_data_filled, x="age_group", y="BMI", hue="흡연여부", palette=["skyblue","salmon"])
plt.title("나이 그룹별 흡연 여부에 따른 BMI 분포")
plt.xlabel("나이 그룹")
plt.ylabel("BMI")
plt.legend(title="흡연 여부")
plt.show()
```

```python
# BMI 기준 연령대별 IQR (순서 유지)
iqr_results = health_data_filled.groupby('age_group', sort=False)['BMI'].quantile([0.25, 0.5, 0.75]).unstack()

for age in age_order:
    q1 = iqr_results.loc[age, 0.25]
    q3 = iqr_results.loc[age, 0.75]
    iqr_val = q3 - q1

    print(f"\n{age}:")
    print(f"Q1 (25%): {q1:.1f}")
    print(f"Q3 (75%): {q3:.1f}")
    print(f"IQR: {iqr_val:.1f}")
    print(f"💡 중간 50%: {q1:.1f}~{q3:.1f} ({iqr_val:.1f} 범위)")
    print(f"✅ 극값 무시 안정 지표")
```

단변량 분석

1. BMI box_plot

```
30대 이하:
Q1 (25%): 22.5
Q3 (75%): 27.6
IQR: 5.1
💡 중간 50%: 22.5~27.6 (5.1 범위)
✅ 극값 무시 안정 지표

30~50대:
Q1 (25%): 21.5
Q3 (75%): 25.9
IQR: 4.5
💡 중간 50%: 21.5~25.9 (4.5 범위)
✅ 극값 무시 안정 지표

50~70대:
Q1 (25%): 22.0
Q3 (75%): 25.9
IQR: 3.9
💡 중간 50%: 22.0~25.9 (3.9 범위)
✅ 극값 무시 안정 지표

70대 이상:
Q1 (25%): 21.5
Q3 (75%): 25.4
IQR: 3.9
💡 중간 50%: 21.5~25.4 (3.9 범위)
✅ 극값 무시 안정 지표
```

```
나이 그룹 + 흡연 여부별 평균 BMI
흡연여부          비흡연     흡연
age_group
30대 이하      24.80  24.84
30~50대      23.45  24.86
50~70대      24.06  24.19
70대 이상      23.45  22.28
```

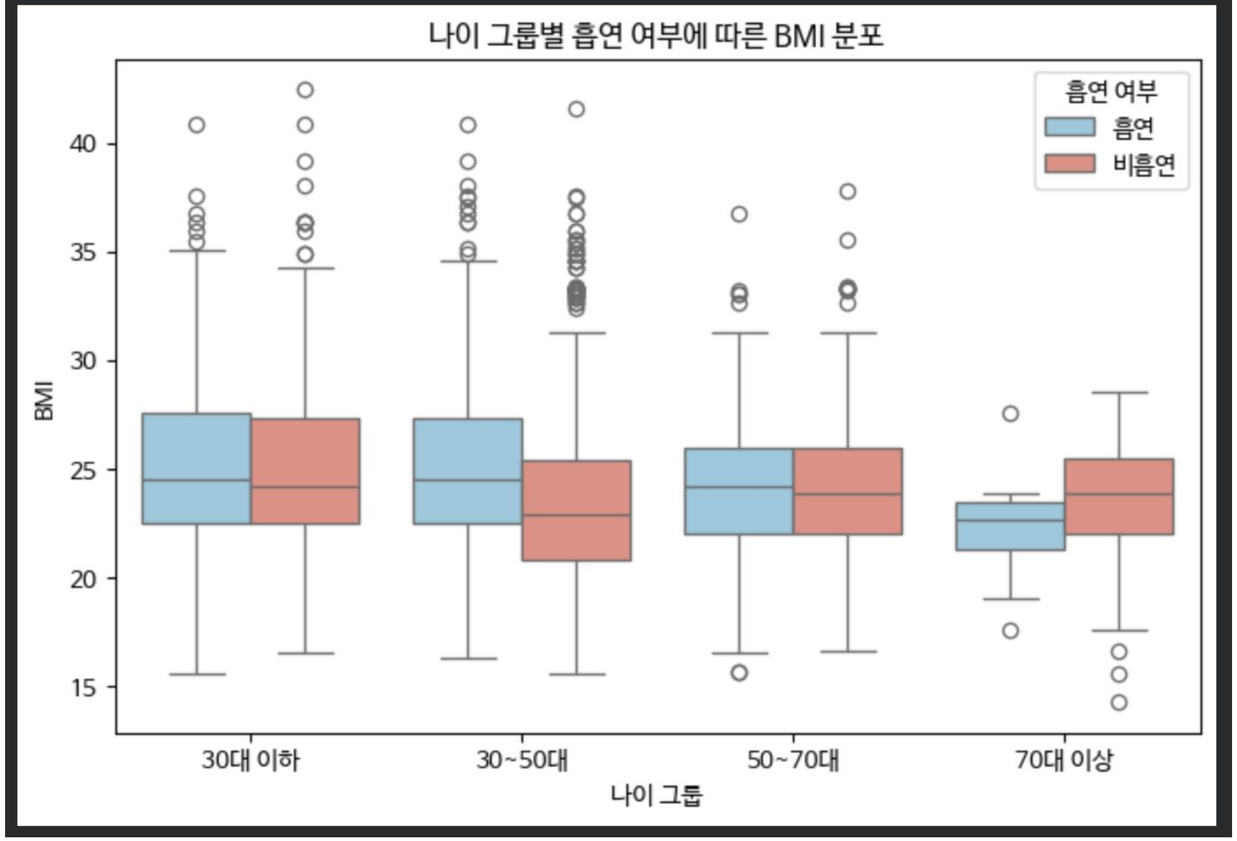

단변량 분석

2. 흡연 여부에 따른 헤모글로빈 기본 통계

```
# 흡연 여부에 따른 헤모글로빈 기본 정보
bp_by_hemoglobin = round(health_data_filled.groupby("흡연여부")["헤모글로빈"].describe(),2)

print(bp_by_hemoglobin)
print()
```

	count	mean	std	min	25%	50%	75%	max
흡연여부								
비흡연	4429.0	14.16	1.56	4.9	13.1	14.2	15.3	19.3
흡연	2571.0	15.44	1.11	8.9	14.8	15.5	16.1	20.9

단변량 분석

2. 헤모글로빈 box_plot

```
#박스 플롯
hemoglobin_mean_age_label = round(health_data_filled.groupby(["age_group", "흡연여부"],observed=False)["헤모글로빈"].mean().unstack(),2)
print("나이 그룹 + 흡연 여부별 평균 헤모글로빈 농도")
print(hemoglobin_mean_age_label)
print()

plt.figure(figsize=(8,5))
sns.boxplot(data=health_data_filled, x="age_group", y="헤모글로빈", hue="흡연여부", palette=["skyblue","salmon"])
plt.title("나이 그룹별 흡연 여부에 따른 평균 헤모글로빈 농도 분포")
plt.xlabel("나이 그룹")
plt.ylabel("헤모글로빈")
plt.legend(title="흡연 여부")
plt.show()
```

```
# 헤모글로빈 기준 연령대별 IQR (순서 유지)
iqr_results = health_data_filled.groupby('age_group', sort=False)['헤모글로빈']

for age in age_order:
    q1 = iqr_results.loc[age, 0.25]
    q3 = iqr_results.loc[age, 0.75]
    iqr_val = q3 - q1

    print(f"\n{age}:")
```

단변량 분석

2. 헤모글로빈 box_plot

```
30대 이하:
Q1 (25%): 15.0
Q3 (75%): 16.2
IQR: 1.2
💡 중간 50%: 15.0~16.2 (1.2 범위)
✅ 극값 무시 안정 지표

30~50대:
Q1 (25%): 13.4
Q3 (75%): 15.6
IQR: 2.2
💡 중간 50%: 13.4~15.6 (2.2 범위)
✅ 극값 무시 안정 지표

50~70대:
Q1 (25%): 13.3
Q3 (75%): 15.3
IQR: 2.0
💡 중간 50%: 13.3~15.3 (2.0 범위)
✅ 극값 무시 안정 지표

70대 이상:
Q1 (25%): 13.1
Q3 (75%): 15.0
IQR: 1.9
💡 중간 50%: 13.1~15.0 (1.9 범위)
✅ 극값 무시 안정 지표
```

```
나이 그룹 + 흡연 여부별 평균 헤모글로빈 농도
흡연여부          비흡연      흡연
age_group
30대 이하      15.56  15.73
30~50대      13.88  15.42
50~70대      14.03  15.20
70대 이상      13.83  14.45
```

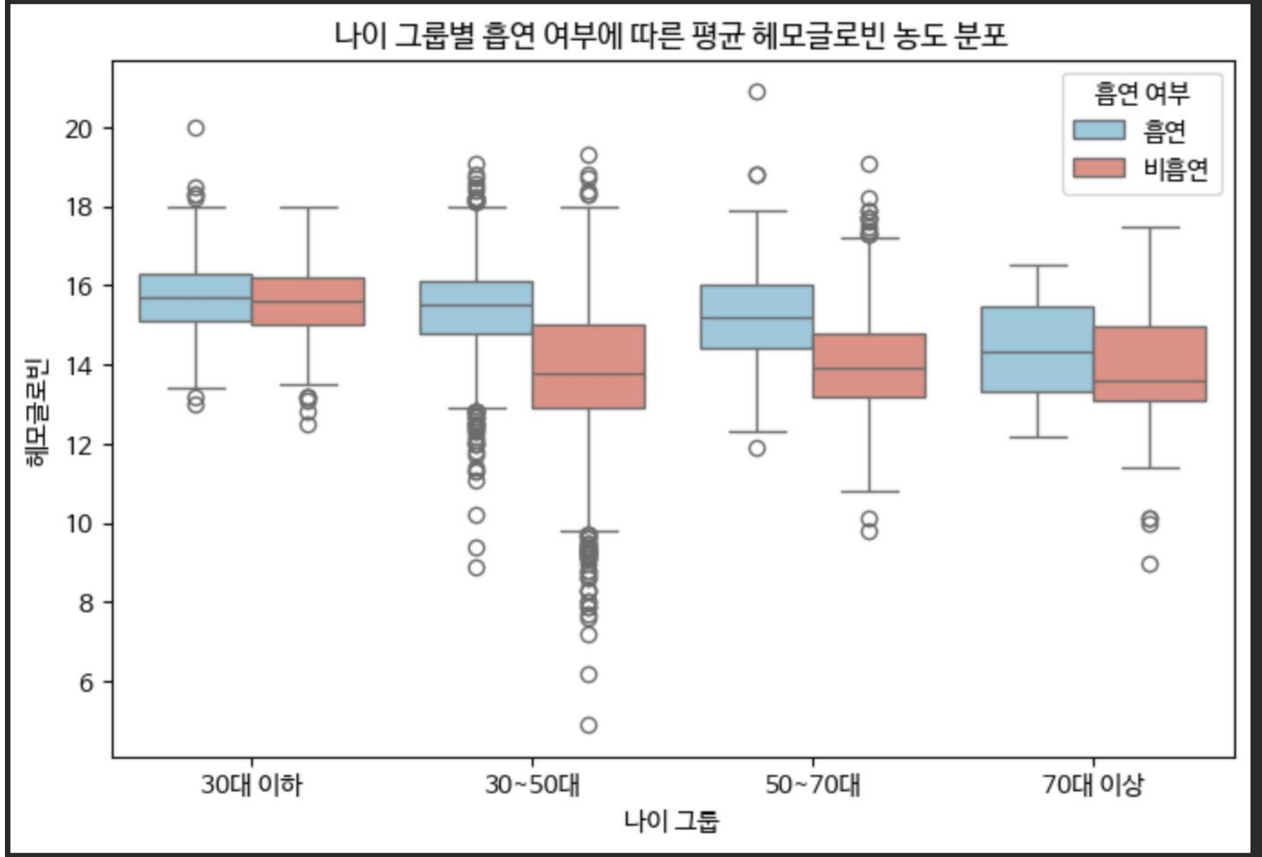

단변량 분석

3. 흡연 여부에 따른 공복 혈당 기본 통계 정보

```python
# 흡연 여부에 따른 공복혈당 기본 통계 정보
bp_by_fbs = round(health_data_filled.groupby("흡연여부")["공복 혈당"].describe(),2)

print(bp_by_fbs)
print()
```

흡연여부	count	mean	std	min	25%	50%	75%	max
비흡연	4429.0	97.54	17.13	57.0	88.0	95.0	102.0	313.0
흡연	2571.0	102.35	26.04	60.0	90.0	97.0	105.0	386.0

```python
# 공복 혈당 기준 연령대별 IQR (순서 유지)
iqr_results = health_data_filled.groupby('age_group', sort=False)['공복 혈당'].quantile([0.25, 0.5, 0.75]).unstack()

for age in age_order:
    q1 = iqr_results.loc[age, 0.25]
    q3 = iqr_results.loc[age, 0.75]
    iqr_val = q3 - q1

    print(f"\n{age}:")
    print(f"Q1 (25%): {q1:.1f}")
    print(f"Q3 (75%): {q3:.1f}")
    print(f"IQR: {iqr_val:.1f}")
    print(f"💡 중간 50%: {q1:.1f}~{q3:.1f} ({iqr_val:.1f} 범위)")
    print(f"✅ 극값 무시 안정 지표")
```

단변량 분석

3. 공복 혈당 box_plot

```
#박스 플롯
fbs_mean_age_label = round(health_data_filled.groupby(["age_group", "흡연여부"],observed=False)["공복 혈당"].mean().unstack(),2)
print("나이 그룹 + 흡연 여부별 평균 공복 혈당 농도")
print(fbs_mean_age_label)
print()

plt.figure(figsize=(8,5))
sns.boxplot(data=health_data_filled, x="age_group", y="공복 혈당", hue="흡연여부", palette=["skyblue","salmon"])
plt.title("나이 그룹별 흡연 여부에 따른 평균 헤모글로빈 농도 분포")
plt.xlabel("나이 그룹")
plt.ylabel("공복 혈당")
plt.legend(title="흡연 여부")
plt.show()
```

```
# 공복 혈당 기준 연령대별 IQR (순서 유지)
iqr_results = health_data_filled.groupby('age_group', sort=False)['공복 혈당'].quantile([0.25, 0.5, 0.75]).unstack()

for age in age_order:
    q1 = iqr_results.loc[age, 0.25]
    q3 = iqr_results.loc[age, 0.75]
    iqr_val = q3 - q1

    print(f"\n{age}:")
    print(f"Q1 (25%): {q1:.1f}")
    print(f"Q3 (75%): {q3:.1f}")
    print(f"IQR: {iqr_val:.1f}")
    print(f"💡 중간 50%: {q1:.1f}~{q3:.1f} ({iqr_val:.1f} 범위)")
    print(f"✅ 극값 무시 안정 지표")
```

단변량 분석

3. 공복 혈당 box_plot

```
30대 이하:
Q1 (25%): 87.0
Q3 (75%): 99.3
IQR: 12.3
💡 중간 50%: 87.0~99.3 (12.3 범위)
✅ 극값 무시 안정 지표

30~50대:
Q1 (25%): 89.0
Q3 (75%): 103.0
IQR: 14.0
💡 중간 50%: 89.0~103.0 (14.0 범위)
✅ 극값 무시 안정 지표

50~70대:
Q1 (25%): 92.0
Q3 (75%): 110.0
IQR: 18.0
💡 중간 50%: 92.0~110.0 (18.0 범위)
✅ 극값 무시 안정 지표

70대 이상:
Q1 (25%): 93.0
Q3 (75%): 107.0
IQR: 14.0
💡 중간 50%: 93.0~107.0 (14.0 범위)
✅ 극값 무시 안정 지표
```

```
나이 그룹 + 흡연 여부별 평균 공복 혈당 농도
흡연여부            비흡연      흡연
age_group
30대 이하        93.42   95.88
30~50대        95.92  102.64
50~70대       102.52  109.44
70대 이상       104.42  112.71
```

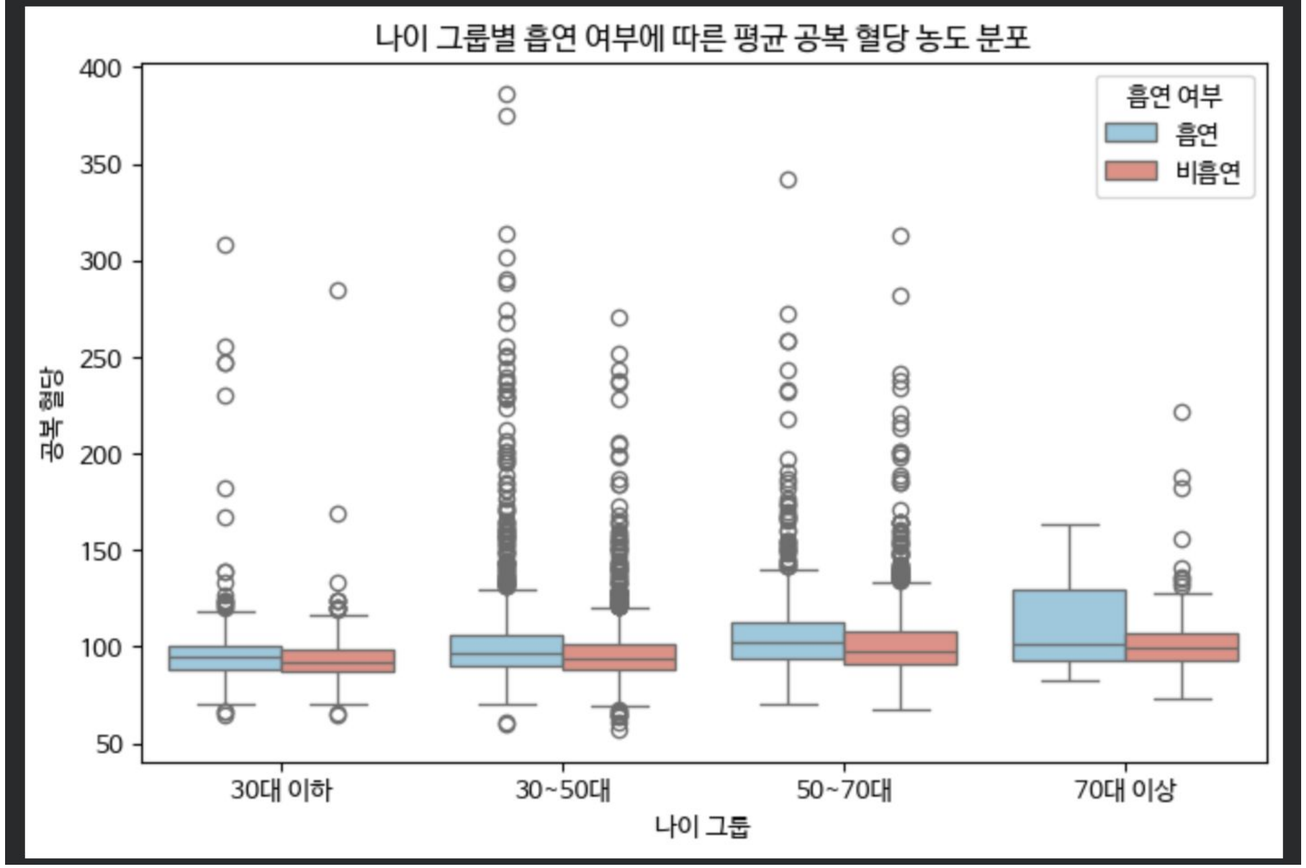

단변량 분석

4. 나이 그룹별 요 단백 막대 그래프

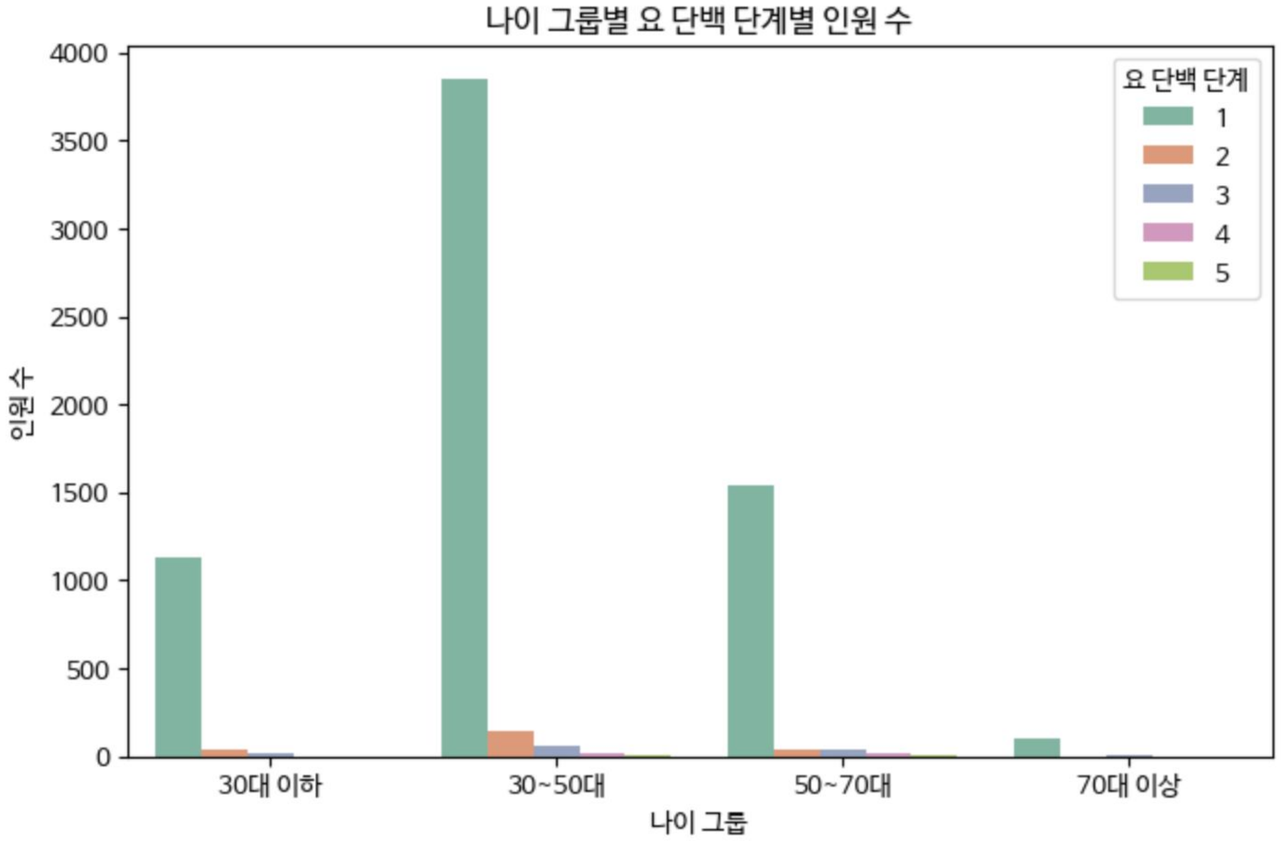

단변량 분석

5. 나이 그룹별 충치 유무 막대 그래프

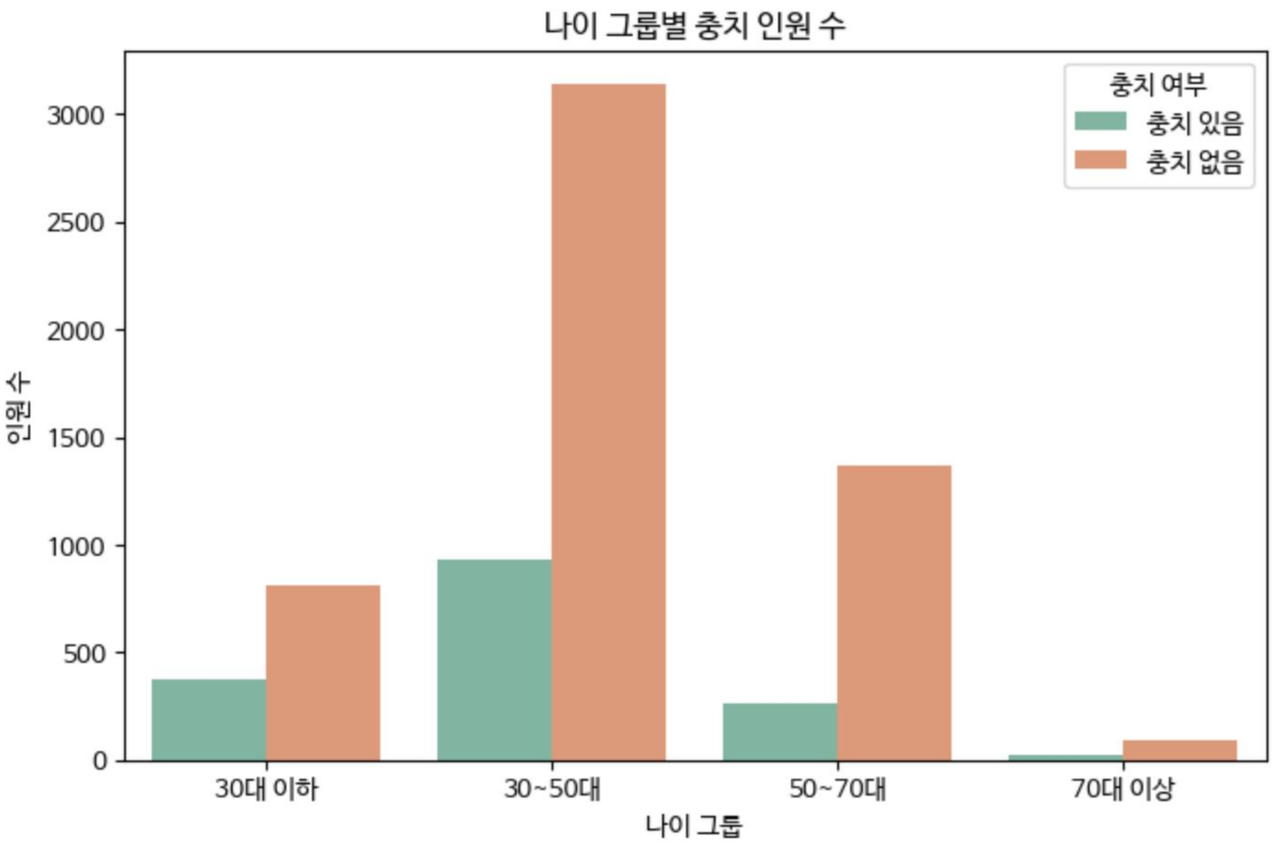

이변량 분석

1. 연령대별 BMI 수치와 흡연 여부 이변량 분석 (t-test 검정)

```python
t_results = []

for age in age_order:
    subset = health_data_filled[health_data_filled["age_group"] == age]

    group0 = subset[subset['흡연여부']=='비흡연']['BMI']
    group1 = subset[subset['흡연여부']=='흡연']['BMI']

    t_stat, p_val = ttest_ind(group0, group1, equal_var=False)  # equal_var=False -> Welch t-test
    t_results.append({
        "나이 그룹": age,
        "t-stat": t_stat.round(2),
        "p-value": p_val.round(2)
    })

# 데이터프레임 변환
t_df = pd.DataFrame(t_results)
print("=== 나이 그룹별 t-검정 결과 (BMI ~ 흡연여부) ===")
print(t_df)
```

```
=== 나이 그룹별 t-검정 결과 (BMI ~ 흡연여부) ===
    나이 그룹  t-stat  p-value
0  30대 이하   -0.19     0.85
1  30~50대  -12.45     0.00
2  50~70대   -0.73     0.47
3  70대 이상    1.66     0.11
```

이변량 분석

1. 연령대별 BMI 수치와 흡연 여부 이변량 t-test 검정 분석 막대

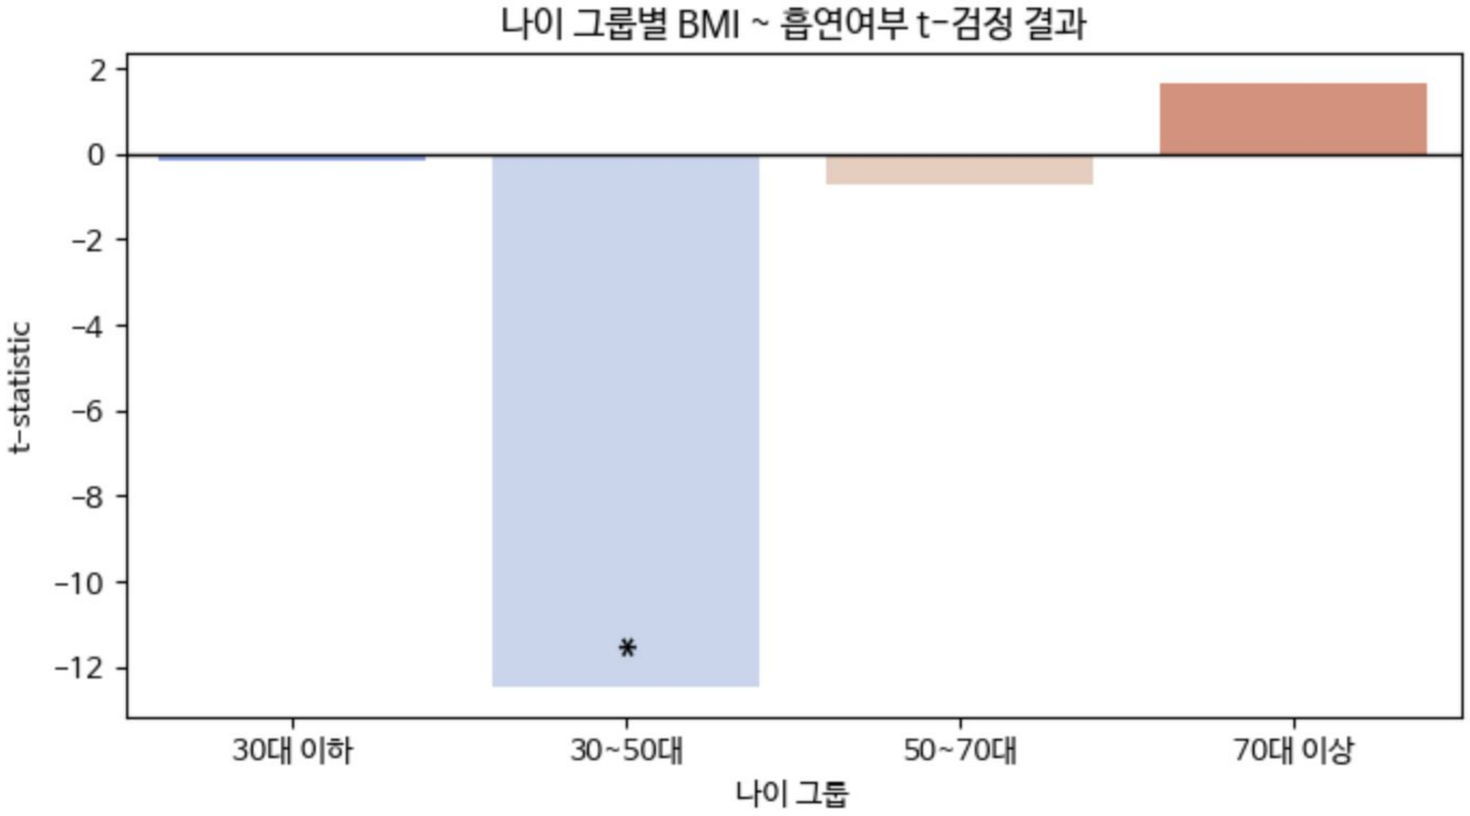

|t| 범위	강도	의학 논문 표현
> 5.0	매우 강함	"highly significant"
3.0~5.0	강함	"significant"
2.0~3.0	보통	"moderately significant"
< 2.0	약함	"not significant"

t = (비흡연자 BMI 평균 - 흡연자 BMI 평균) / 표준오차

- 30대 이하 BMI 농도: 흡연자 > 비흡연자
- **30~50대 BMI 농도 : 흡연자 >>>> 비흡연자**
- 50~70대 BMI 농도 : 흡연자 > 비흡연자
- 70대 이상 BMI 농도: 흡연자 > 비흡연자

이변량 분석

2. 연령대별 헤모글로빈 수치와 흡연 여부 이변량 분석 (t-test 검정)

```python
t_results = []

for age in age_order:
    subset = health_data_filled[health_data_filled["age_group"] == age]

    group0 = subset[subset['흡연여부']=='비흡연']['헤모글로빈']
    group1 = subset[subset['흡연여부']=='흡연']['헤모글로빈']

    t_stat, p_val = ttest_ind(group0, group1, equal_var=False)  # equal_var=False -> Welch t-test
    t_results.append({
        "나이 그룹": age,
        "t-stat": t_stat.round(2),
        "p-value": p_val.round(2)
    })

# 데이터프레임 변환
t_df = pd.DataFrame(t_results)
print("=== 나이 그룹별 t-검정 결과 (헤모글로빈 ~ 흡연여부) ===")
print(t_df)
```

```
=== 나이 그룹별 t-검정 결과 (헤모글로빈 ~ 흡연여부) ===
    나이 그룹  t-stat  p-value
0  30대 이하   -3.11     0.00
1  30~50대  -35.59     0.00
2  50~70대  -17.03     0.00
3  70대 이상   -1.59     0.13
```

이변량 분석

2. 연령대별 헤모글로빈 수치와 흡연 여부 이변량 t-test 검정 분석 막대

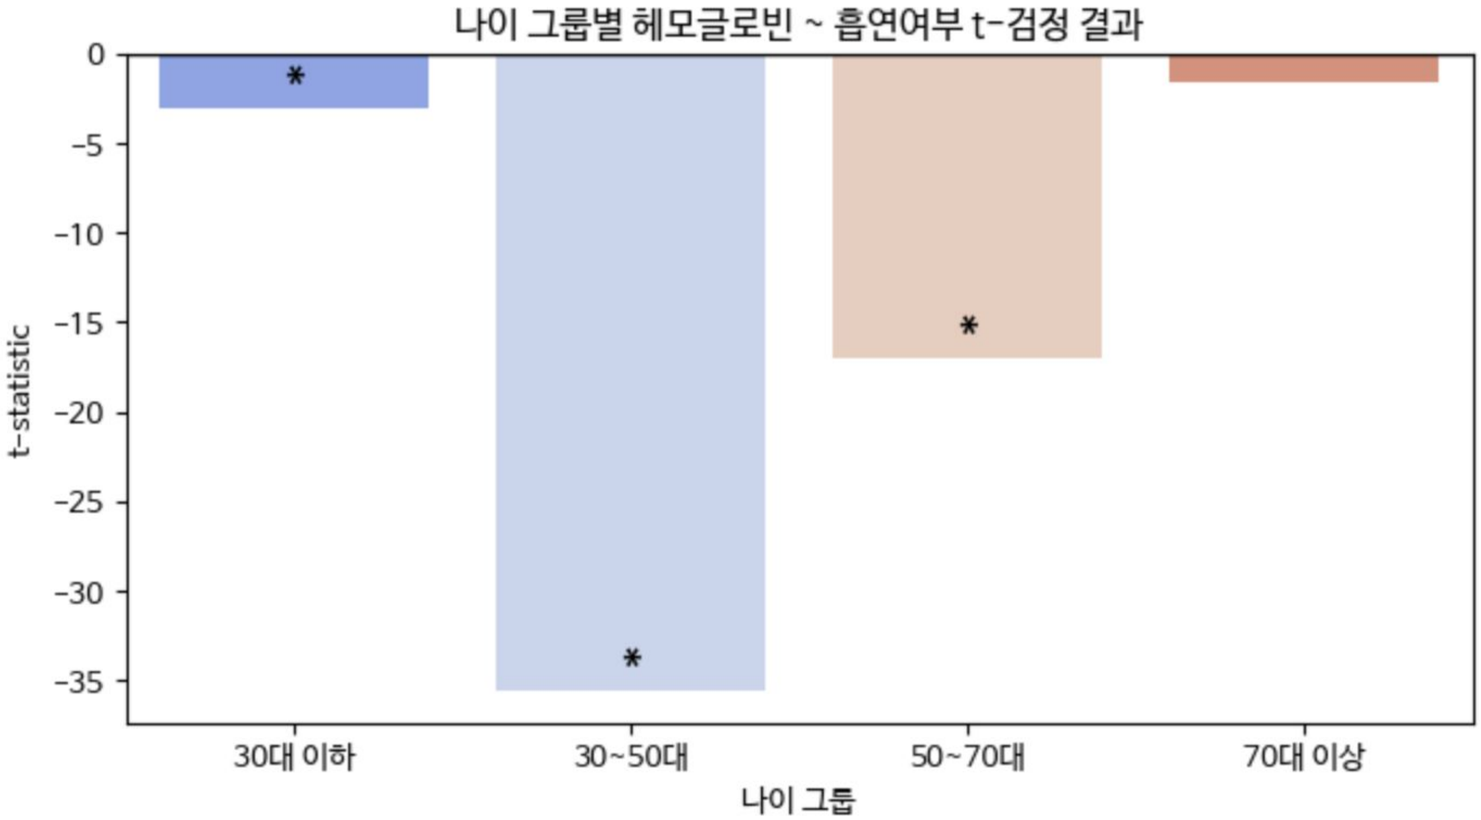

|t| 범위	강도	의학 논문 표현
> 5.0	매우 강함	"highly significant"
3.0~5.0	강함	"significant"
2.0~3.0	보통	"moderately significant"
< 2.0	약함	"not significant"

t = (비흡연자 헤모글로빈 평균 - 흡연자 헤모글로빈 평균) / 표준오차

- **30대 이하 헤모글로빈 농도: 흡연자 >>> 비흡연자**
- **30~50대 헤모글로빈 농도 : 흡연자 >>>> 비흡연자**
- **50~70대 헤모글로빈 농도 : 흡연자 >>>> 비흡연자**
- 70대 이상 헤모글로빈 농도: 흡연자 > 비흡연자

이변량 분석

3. 연령대별 공복 혈당 수치와 흡연 여부 이변량 분석 (t-test 검정)

```python
t_results = []

for age in age_order:
    subset = health_data_filled[health_data_filled["age_group"] == age]

    group0 = subset[subset['흡연여부']=='비흡연']['공복 혈당']
    group1 = subset[subset['흡연여부']=='흡연']['공복 혈당']

    t_stat, p_val = ttest_ind(group0, group1, equal_var=False)  # equal_var=False -> Welch t-test
    t_results.append({
        "나이 그룹": age,
        "t-stat": t_stat.round(2),
        "p-value": p_val.round(2)
    })

# 데이터프레임 변환
t_df = pd.DataFrame(t_results)
print("=== 나이 그룹별 t-검정 결과 (공복 혈당 ~ 흡연여부) ===")
print(t_df)
```

```
=== 나이 그룹별 t-검정 결과 (공복 혈당 ~ 흡연여부) ===
    나이 그룹  t-stat  p-value
0  30대 이하   -2.58     0.01
1  30~50대   -9.08     0.00
2  50~70대   -4.53     0.00
3  70대 이상   -1.13     0.28
```

이변량 분석

3. 연령대별 공복 혈당 수치와 흡연 여부 이변량 t-test 검정 분석 막대 그래프

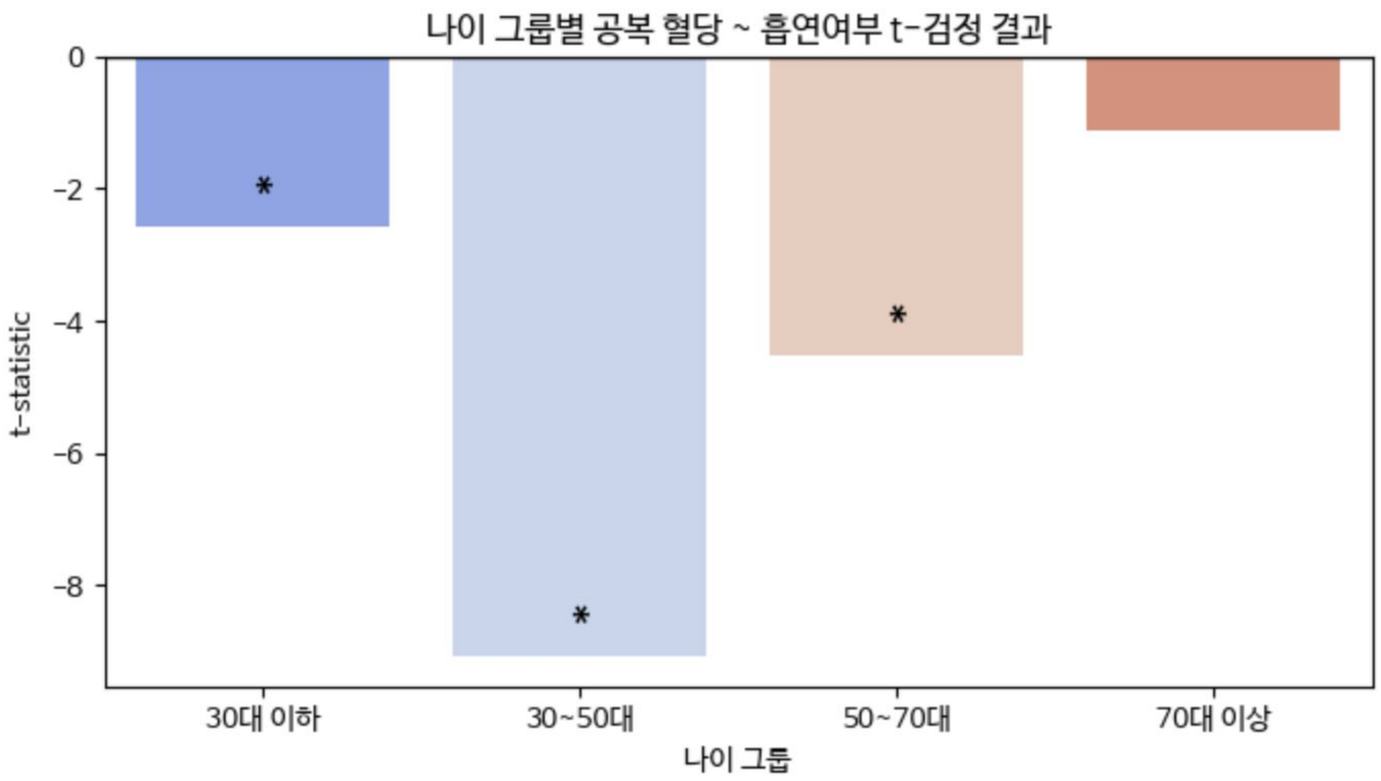

|t| 범위	강도	의학 논문 표현
> 5.0	매우 강함	"highly significant"
3.0~5.0	강함	"significant"
2.0~3.0	보통	"moderately significant"
< 2.0	약함	"not significant"

t = (비흡연자 공복 혈당 평균 - 흡연자 공복 혈당 평균) / 표준오차

- 30대 이하 공복 혈당 농도: 흡연자 >> 비흡연자
- **30~50대 공복 혈당 농도 : 흡연자 >>>> 비흡연자**
- **50~70대 공복 혈당 농도 : 흡연자 >>> 비흡연자**
- 70대 이상 공복 혈당 농도: 흡연자 > 비흡연자

이변량 분석

4. 연령대별 요 단백 수치와 흡연 여부 이변량 분석 (카이제곱검정)

```python
# 이변량 라이브러리
from scipy.stats import chi2_contingency # 카이제곱
from scipy.stats import ttest_ind # t-test

age_order = ["30대 이하", "30~50대", "50~70대", "70대 이상"]

# 요단백 카이제곱 분석
for age in age_order:
    subset = health_data_filled[health_data_filled["age_group"] == age]
    table = pd.crosstab(subset['요 단백'], subset['흡연여부'])
    chi2, p, dof, expected = chi2_contingency(table)
    print(f"{age} 그룹:")
    print(table)
    print(f"p-value: {p:.4f}")
    if p < 0.05:
        print("→ 요 단백과 흡연 여부는 통계적으로 연관 있음★ (유의수준 5%)")
    else:
        print("→ 요 단백과 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)")
```

```
30대 이하 그룹:
흡연여부  비흡연   흡연
요 단백
1      594  537
2       25   18
3        5    8
4        2    0
p-value: 0.3372
→ 요 단백과 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)
30~50대 그룹:
흡연여부   비흡연    흡연
요 단백
1      2361  1488
2        98    45
3        35    21
4         9     7
5         2     2
p-value: 0.4851
→ 요 단백과 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)
50~70대 그룹:
흡연여부   비흡연   흡연
요 단백
1      1137  400
2        31   12
3        22   12
4         9    7
5         4    0
p-value: 0.2431
→ 요 단백과 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)
70대 이상 그룹:
흡연여부  비흡연  흡연
요 단백
1       88  13
2        2   0
3        3   1
5        2   0
p-value: 0.7728
→ 요 단백과 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)
```

이변량 분석

4. 연령대별 흡연 여부에 따른 요 단백 막대 그래프

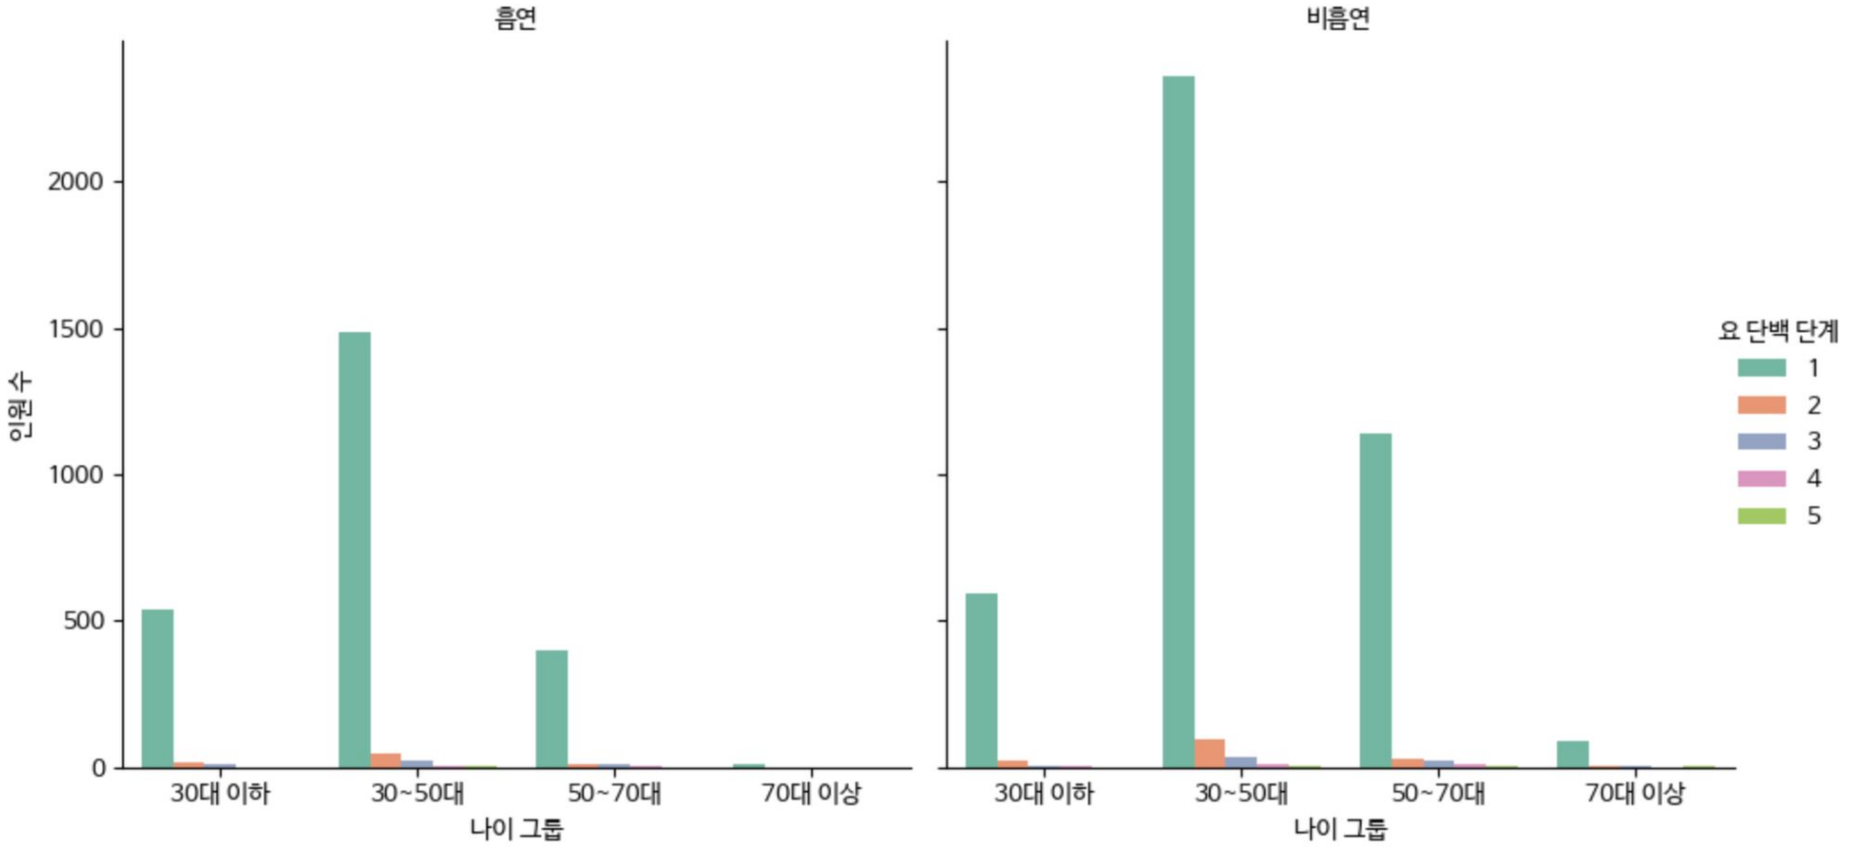

이변량 분석

5. 연령대별 충치 유무와 흡연 여부 이변량 분석 (카이제곱검정)

```python
for age in age_order:
    subset = health_data_filled[health_data_filled["age_group"] == age]
    table = pd.crosstab(subset['충치'], subset['흡연여부'])
    chi2, p, dof, expected = chi2_contingency(table)
    print(f"{age} 그룹:")
    print(table)
    print(f"p-value: {p:.4f}")
    if p < 0.05:
        print("→ 충치와 흡연 여부는 통계적으로 연관 있음★ (유의수준 5%)")
    else:
        print("→ 충치와 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)")
```

```
30대 이하 그룹:
흡연여부  비흡연   흡연
충치
0      449  364
1      177  199
p-value: 0.0106
→ 충치와 흡연 여부는 통계적으로 연관 있음★ (유의수준 5%
30~50대 그룹:
흡연여부   비흡연    흡연
충치
0      2018  1121
1       487   442
p-value: 0.0000
→ 충치와 흡연 여부는 통계적으로 연관 있음★ (유의수준 5%)
50~70대 그룹:
흡연여부   비흡연   흡연
충치
0      1018  349
1       185   82
p-value: 0.0927
→ 충치와 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)
70대 이상 그룹:
흡연여부  비흡연  흡연
충치
0       76  13
1       19   1
p-value: 0.4292
→ 충치와 흡연 여부는 통계적으로 연관 없음 (유의수준 5%)
```

이변량 분석

5. 연령대별 흡연 여부에 따른 충치 막대 그래프

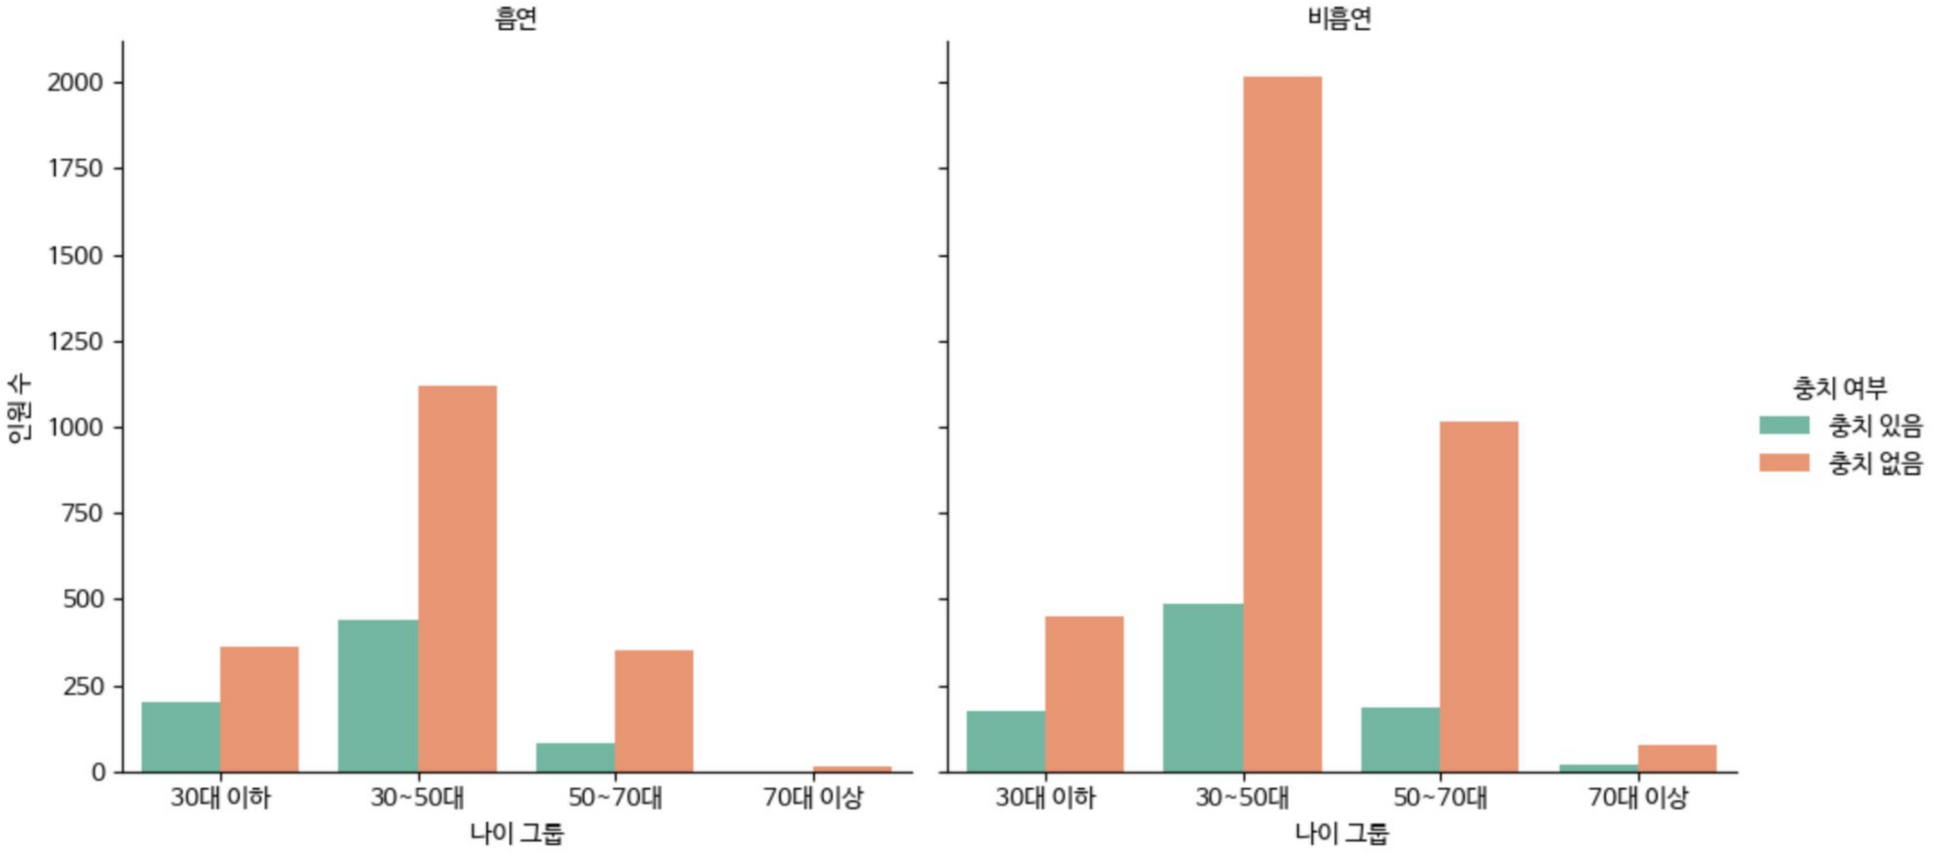

상관관계 시각화

상관 관계 강도	범위
거의 없음	0~0.1
약한	0.1~0.2
중간	0.2~0.3
강한	0.3~

- 가장 강한 상관관계 값이 0.46이라는 점을 기준으로 상대적 상관관계 설정

상관관계 시각화

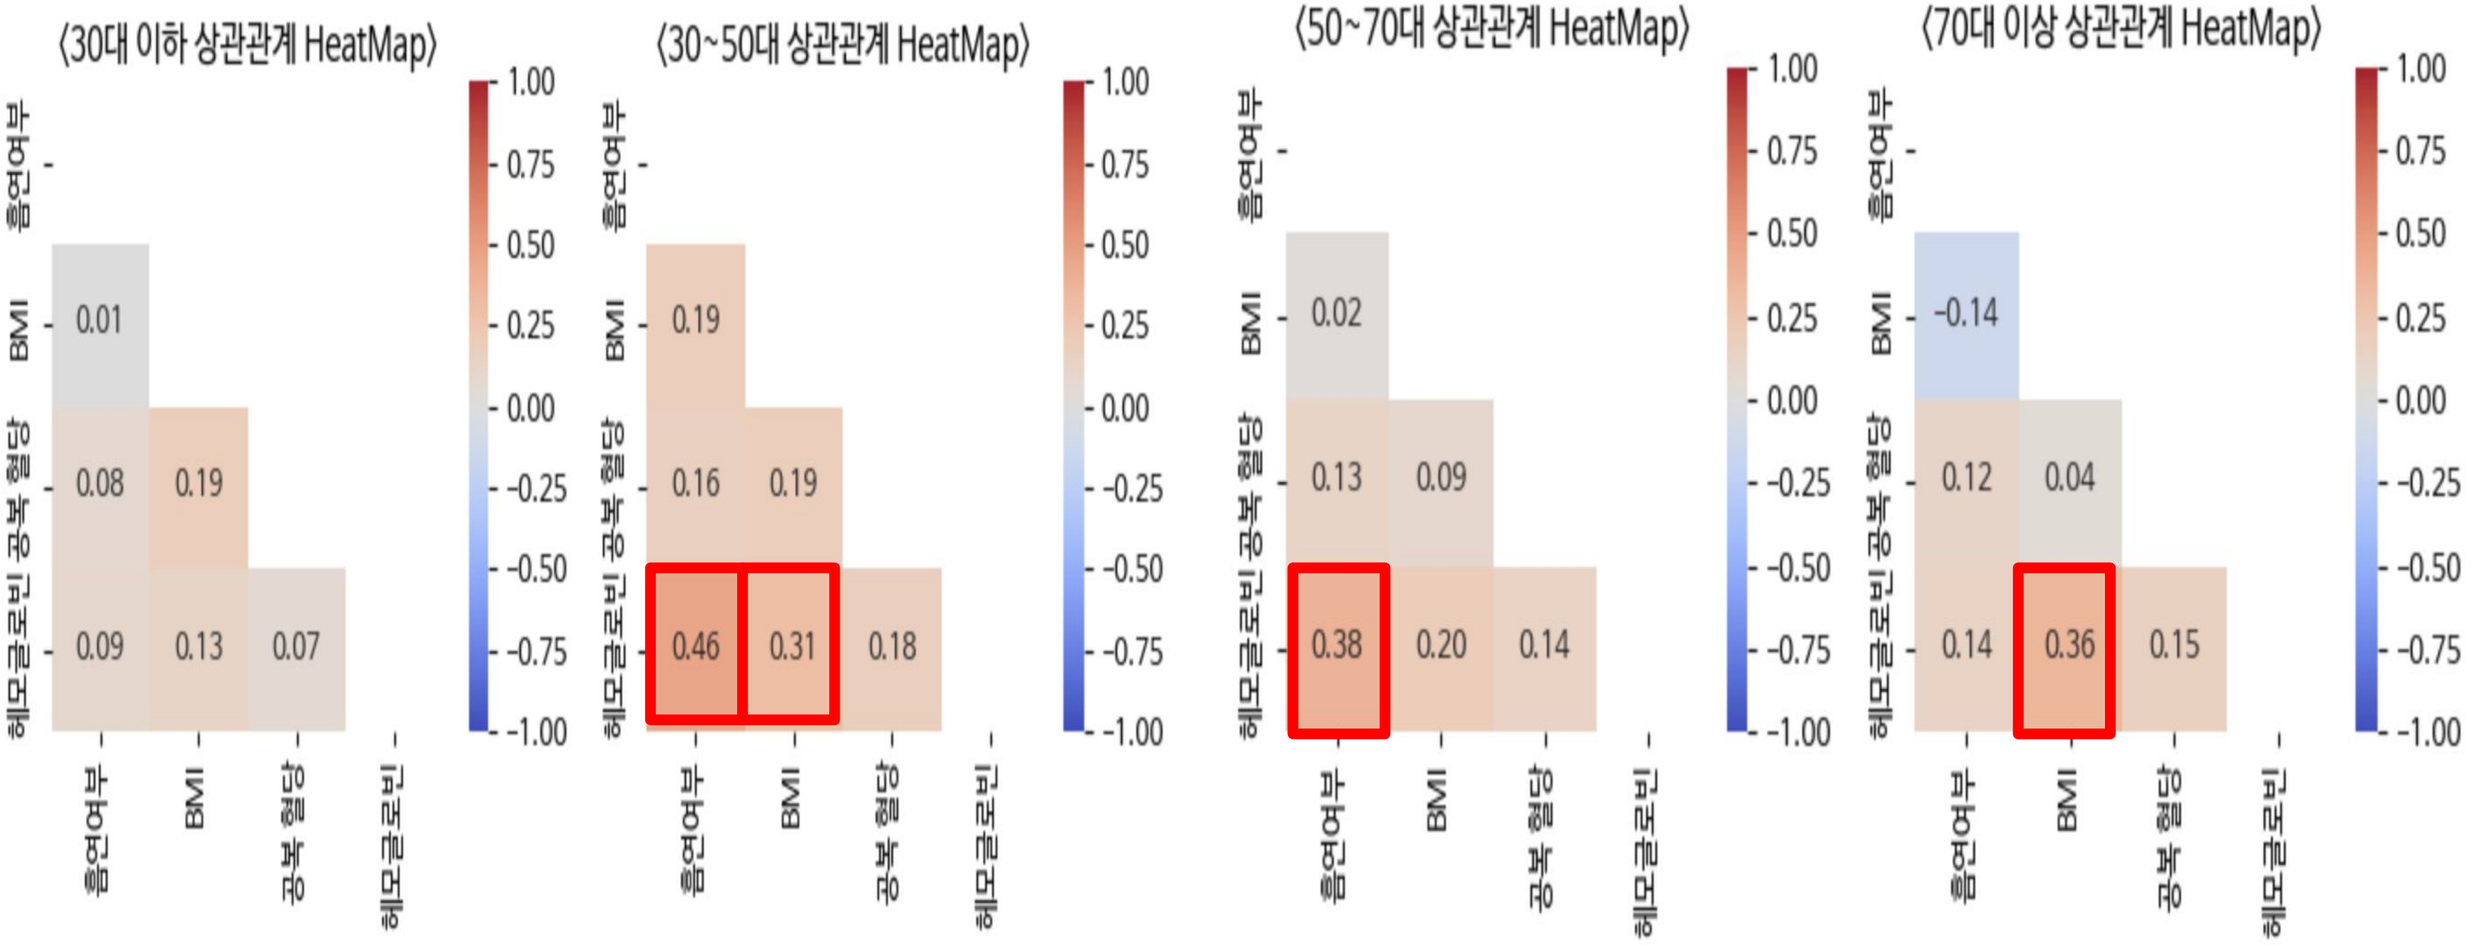
〈30대 이하 상관관계 HeatMap〉
흡연여부
BMI
공복 혈당
헤모글로빈
0.01
0.08 0.19
0.09 0.13 0.07
〈30~50대 상관관계 HeatMap〉
0.19
0.16 0.19
0.46 0.31 0.18
〈50~70대 상관관계 HeatMap〉
0.02
0.13 0.09
0.38 0.20 0.14
〈70대 이상 상관관계 HeatMap〉
-0.14
0.12 0.04
0.14 0.36 0.15
1.00
0.75
0.50
0.25
0.00
-0.25
-0.50
-0.75
-1.00

분석 결과 요약

연령대별 흡연 영향의 차이	타 연령대 대비 흡연 여부와 신체 지표간의 상관계수가 30대에서 50대 사이에서 가장 높게 측정됨.
흡연 여부에 따른 BMI 변화	흡연 여부와 BMI 사이에는 통계적으로 유의미한 음(-)의 상관관계가 관찰됨. 상관계수가 -0.14로 나타난 것으로 보아 흡연이 신체 질량 지수에 영향을 주고 있음. 30~50대 그룹에서 그 영향력이 강하게 나타남.
흡연 여부에 따른 헤모글로빈 변화	흡연자는 비흡연자에 비해 헤모글로빈 수치가 유의하게 높은 경향을 보임.
흡연 여부에 따른 공복 혈당 변화	흡연자는 비흡연자에 비해 공복 혈당 수치가 유의하게 높음
흡연 여부와 요 단백의 상관관계	전 연령대 p-value > 0.05 이므로 통계적 유의성이 없고 흡연 여부가 요 단백에 즉각적이고 직접적인 변화를 주지 않음.
흡연 여부와 충치 발생의 상관관계	30대 이하 & 30~50대: p-value < 0.05 이므로 통계적 유의성이 확인되어 50대 미만 젊은 층 및 중장년층에서 흡연이 충치에게 영향을 줌.

결론

1. 30~50대 중장년층에서 흡연의 영향력이 매우 큼
2. 흡연과 헤모글로빈 수치가 유의미한 상승관계를 보임
3. 공복혈당수치 상승을 통한 당뇨 위험성 확인
4. 흡연 여부에 따른 50대 미만 젊은 층에서 충치 발생 상관성을 보임
5. BMI변화를 통한 흡연이 신체에 미치는 영향을 볼 수 있음
6. 흡연과 신장 기능(요단백)의 독립성을 확인할 수 있음

인사이트

헤모글로빈 흡연/비흡연 여부의 **핵심 피쳐**라는 점에 대한 고찰 (고농도 헤모글로빈)

0. 헤모글로빈은 폐에서 산소를 받아 몸 전체로 운반하는 역할을 함
1. 흡연 시 일산화탄소(CO) 폐로 들어감
2. CO는 산소보다 헤모글로빈 결합력이 200배 강함 -> CO가 산소보다 헤모글로빈과 결합할 확률 높음
3. 산소 운반할 헤모글로빈 부족으로 인해 적혈수 생성 골수(뼈안)에서 **헤모글로빈 추가 생산 진행**
4. 따라서 만성 흡연자의 경우 비흡연자보다 상대적으로 높은 헤모글로빈 농도 수치가 나타날 확률 **높음**

```
# Thakur KT, Westover MB. Cerebral infarction due to smoker's polycythemia. BMJ Case Rep. 2011 Oct 28;2011:bcr0820114714. doi: 10.1136/
# 흡연 여부와 헤모글로빈 조건 충족 시 혈전증·뇌졸중 3배 위험
health_data_filled['hb_smoking_risk'] = ((health_data_filled['흡연여부'] == '흡연') & (health_data_filled['헤모글로빈'] >= 16.5))
print(f"논문 기준 고위험군: {health_data_filled['hb_smoking_risk'].sum()}명")
print("→ 혈전증·뇌졸중 3배 위험!")
```

```
논문 기준 고위험군: 437명
→ 혈전증·뇌졸중 3배 위험!
```

인사이트

헤모글로빈 흡연/비흡연 여부의 **핵심 피쳐**라는 점에 대한 고찰 (빈혈 + 흡연자)

0. 헤모글로빈이 정상 기준보다 낮은 경우(빈혈),
흡연 여부와 빈혈(헤모글로빈이 11이하인 경우) 조건 충족 시, 만성신부전 1.2배 위험

Choi HS, Han KD, Oh TR, Kim CS, Bae EH, Ma SK, Kim SW. Smoking and risk of incident end-stage kidney disease in general population: A Nationwide Population-based Cohort Study from Korea. Sci Rep. 2019 Dec 20;9(1):19511. doi: 10.1038/s41598-019-56113-7. PMID: 31862942; PMCID: PMC6925223.

```
# Choi HS, Han KD, Oh TR, Kim CS, Bae EH, Ma SK, Kim SW. Smoking and risk of incident end-stage kidney disease in gen
# 흡연 여부와 빈혈 조건 충족 시 만성신부전 1.2배 위험
health_data_filled['anemia_smoking_risk'] = ((health_data_filled['흡연여부'] == '흡연') & (health_data_filled['헤모글로빈']
print(f"논문 기준 고위험군: {health_data_filled['anemia_smoking_risk'].sum()}명")
print("→ 만성신부전 1.2배 위험!")
```

```
논문 기준 고위험군: 3명
→ 만성신부전 1.2배 위험!
```

인사이트

요단백과 흡연/비흡연 여부 관련 인사이트

1. 흡연은 신장 기능을 저하 시키고 요 단백를 유발한다.
2. 흡연은 당뇨병 발병 위험을 높이고, 혈당 조절을 어렵게 만든다.
3. 당뇨병 환자의 단백뇨 신호는 신장 건강에 중요한 신호이므로 흡연자 당뇨병 환자는 만성신질환이나 신부전에 대한 주의가 필요하다.(흡연이 비교적 건강한 일반인의 사구체여과율 및 단백뇨 발생에 미치는 이중효과'.2009.)

팀원 별 소감

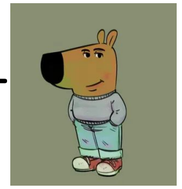

이름	소감
박진영	객관적인 데이터를 직접 다뤄보고 분석할 수 있어서 좋았던 반면에 단변량 분석을 넘어 지표 간의 복합적인 관계를 보는 이변량 분석이나, 이를 한눈에 보여주는 시각화 단계에서는 아직 어려움을 느껴 공부가 더 필요하고 데이터 수치를 읽고 해석하는 능력도 길러야겠다고 생각한 시간이었습니다. chill stack 조원분들 모두 수고하셨습니다 !
설윤재	많은 용량의 데이터를 분석해보고 조각조각 잘라서 의미를 찾아내는 부분이 재미있었다. 하지만 코드를 작성하는 부분에서 너무 많이 헷갈리고 익숙하지 않은 코드들이 자꾸 나오면서 더 어려웠던것 같다. 통계를 하는 부분에서도 결과를 도출해 내는데 조원분들께서 너무 잘 해주셔서 감사. 진행하는 내내 많은 도움을 받을 수 있어 너무 좋았어서 감사드립니다.
정은혜	프로젝트를 진행하면서 생각보다 많이 부족하다는 것을 느꼈고, 팀원분들이 너무 잘 하셔서 같이 진행하기보단 배우는 입장이었습니다. 그리고 프로젝트를 진행하니 데이터 분석이란게 어떤 의미 인지를 조금 알게 된것 같습니다. 스스로 학습하는데 있어 부족함을 느끼긴 했지만, 귀중한 경험을 해서 개인적으로는 좋았습니다.
진태준	통계 관련 용어 및 결과 해석하는 것에 대해 많이 부족함을 느낌. 데이터에서 유의미한 결과를 뽑아 내는 과정이 정말로 어렵다고 생각함. 조금 더 능동적으로 데이터를 가지고 놀 줄 아는 역량을 키워야 겠다는 생각이 들었음. 개발 프로젝트는 처음인데 좋은 경험이 된 것 같아 좋았다. 조원분들에게 고맙다고 전하고 싶다.